Dematus 3.0: отчет по проделанной работе

Краткий итог изменений по проекту аналитики Dota 2 драфтов, snapshot-хранилищу, STRATZ weekly data и подготовке Dataset для будущей ML-модели.

Было	Dematus считал прогноз, но результаты могли плавать из-за weekly-пересчета STRATZ и отсутствия воспроизводимых snapshot'ов.
Стало	Каждый расчет сохраняется в локальную базу, STRATZ-ответы фиксируются, 4w/8w/12w данные собираются отдельно, Dataset выгружается в Google Sheets.
Главная цель	Сделать прогнозы воспроизводимыми и подготовить чистый фундамент для анализа, baseline-проверок и будущей ML-модели.

1. Исходная проблема

- Модель технически работала, но на живых турнирах качество сильно прыгало от турнира к турниру.

- Главный риск: STRATZ пересчитывает агрегаты по неделям, поэтому один и тот же драфт мог получить другой прогноз позже.

- Был риск data leakage: при бэктесте можно случайно использовать данные, которых не было в момент реальной игры.

- Google Sheets был удобной витриной, но не надежным основным хранилищем данных.

2. Snapshot-хранилище

- Добавлена локальная база snapshot'ов: каждый live/MatchID расчет сохраняется как отдельная запись.

- Snapshot хранит команды, героев, источник, время, STRATZ payload, рассчитанные признаки, Google Sheets payload и model_version.

- Google Sheets теперь считается витриной, а локальная SQLite-база - главным хранилищем воспроизводимых данных.

- Для каждого snapshot сохраняются baseline STRATZ buckets текущей формулы: hero winrate 1w, hero tempo 1w, synergy 4w.

3. DLTV extension и MatchID

Важно: новые слои работают и для MatchID, и для live DLTV extension.

- MatchID расчет сохраняет snapshot, baseline buckets и строку в Google Sheets.

- Live DLTV extension делает то же самое, только match_id в базе будет пустым, а в Google Sheets строка идет как LIVE.

- После live-расчета можно открыть вкладку Snapshots и вручную собрать 4w/8w/12w для этого snapshot.

- Фактический winner live-игры пока автоматически не подтягивается после матча. Это отдельный будущий шаг.

4. 4w / 8w / 12w STRATZ buckets

- Мы не просим STRATZ отдать готовую силу драфта за 4/8/12 недель.

- Мы запрашиваем weekly-агрегаты STRATZ по героям, ролям, темпу и synergy вокруг timestamp snapshot'a.

- Dematus сам собирает окна: 4w = последние 4 недели, 8w = последние 8 недель, 12w = последние 12 недель.

- Collector оптимизирован: он не запрашивает повторно одинаковые недели для 4w, 8w и 12w.

- Уже собранные 4w/8w/12w buckets защищены от случайной перезаписи.

5. Интерфейс Snapshots

- Добавлена вкладка Snapshots: можно смотреть сохраненные расчеты и полный JSON.

- Видно, собран ли полный набор 4w/8w/12w.

- Есть кнопка Collect 4w/8w/12w для конкретного snapshot.

- Если набор уже собран, кнопка становится Already collected и не перезаписывает данные.

- Есть кнопка Export Dataset для выгрузки подготовленной ML-таблицы в Google Sheets.

6. Google Sheets: Dematus 3.0 и Dataset

- Лист Dematus 3.0 остается рабочей live-витриной для ставок и ручных коэффициентов.

- Создан отдельный лист Dataset в той же Google таблице.

- Dataset содержит одну строку на snapshot: metadata, winner, Dematus odds, готовность 4w/8w/12w, feature-колонки.

- Raw JSON в Google Sheets не выгружается. Он остается в локальной базе, чтобы таблица не раздувалась.

- Ручные bookmaker_odds_radiant и bookmaker_odds_dire защищены: повторный Export Dataset их не затирает.

7. Первые feature-колонки для Dataset

Для каждого окна 4w, 8w и 12w сейчас выгружаются:

- средний hero winrate Radiant и Dire;

- разница winrate между Radiant и Dire;

- суммарный match count по героям;

- synergy Radiant и Dire;

- diff synergy;

- matchup advantage;

- tempo winrate на 20-й и 60-й минуте.

8. Что важно помнить

STRATZ API	4w/8w/12w collector лучше запускать осознанно, не автоматически на каждый live-клик. Так мы бережем API лимиты.
Snapshot	Главный смысл snapshot - зафиксировать, что модель видела в момент расчета. Поэтому повторная перезапись 4w/8w/12w запрещена.

Bookmaker odds	Пока вводятся вручную в Dataset. Автоматический сбор коэффициентов еще не делали.
Winner	Для live-игр фактический результат пока нужно будет дозаполнять отдельно.

9. Проверки и простая оптимизация

- Проверены тестами MatchID, DLTV extension, Snapshots, Dataset export, feature aggregation и 4w/8w/12w collector.

- Dataset export оптимизирован: buckets заранее подгружаются вместе со snapshot'ами, чтобы на большом объеме меньше дергать базу.

- Лишние колонки bookmaker_source и bookmaker_captured_at были убраны, чтобы не съезжала структура Dataset.

10. Что делаем дальше

- Сделать readiness/baseline analysis кодом, без добавления лишних колонок в Google Sheets.

- Посчитать: сколько usable строк есть, сколько с winner, сколько с bookmaker odds, сколько с полными 4w/8w/12w features.

- Проверить текущий baseline Dematus: accuracy, ROI, edge thresholds, фавориты/андердоги, слабый и сильный сигнал.

- После baseline analysis перейти к первой ML-модели: простая логистическая регрессия или gradient boosting, train/test split строго по времени.

- Позже подумать об автоматическом подтягивании фактического winner и более удобном вводе bookmaker odds.

Короткий вывод

Мы перевели Dematus из режима 'расчет + таблица' в режим воспроизводимого пайплайна: snapshot, сохраненные STRATZ buckets, 4w/8w/12w окна, Dataset и первые признаки для анализа. Это еще не ML-модель, но уже нормальный фундамент, на котором можно проверять идею без data leakage и без зависимости от будущих weekly-пересчетов STRATZ.